

위상 동기화 기반 딥러닝에서의 고차원 잠재 표현과 심층 표현 학습

1. 개요 (Introduction)

기존의 Restricted Boltzmann Machine(RBM)이나 심층 신경망(DNN)은 입력 데이터의 확률 분포를 통계역학적 평형 상태(Equilibrium State)로 유도하거나 목적 함수의 기하학적 매핑을 통해 고차원 잠재 표현(Latent Representation)을 압축하고 복원해 왔습니다. 이 패러다임에서 잠재 표현은 고차원 유클리드 공간의 정적 벡터 $\mathbf{z} \in \mathbb{R}^d$ (뉴런의 활성화 강도)로 정의됩니다.

반면, 결합 진동자의 위상 동기화(Phase Synchronization) 기반 딥러닝에서는 표현 학습의 물리적·수학적 대상이 근본적으로 달라집니다. 본 보고서는 이 새로운 패러다임 내에서 고차원 잠재 표현이 어떻게 정의되고, 심층 표현 학습(Deep Representation Learning)이 어떠한 동역학적 메커니즘을 통해 데이터의 압축과 기하학적 분리를 실현하는지 규명합니다.

2. 고차원 잠재 표현의 기하학적·동역학적 정의

위상 동기화 기반 딥러닝(예: AKOrN, KuraNet, KuramotoGPT)에서 고차원 잠재 표현은 단순한 활성화 강도의 스칼라 벡터가 아닙니다. 이는 고차원 원형 매니폴드(Circular Manifold) 위에서 회전하는 진동자들의 동적 상태와 이들이 그리는 궤적(Trajectory)으로 구성됩니다.

2.1. 잠재 공간의 기하학적 위상 구조

기존 뉴런의 잠재 벡터가 $\mathbb{R}^d$ 공간에 위치한다면, 위상 기반 뉴런들의 잠재 표현 공간은 고차원 토러스(Torus) $T^N = (S^1)^N$ 또는 하이퍼스피어(Hypersphere) S^{d-1} 의 표면으로 정의됩니다

- 개별 상태 변수: 각 잠재 뉴런 i 는 단위원 위의 위상 $\theta_i \in [0, 2\pi]$ 를 가집니다. 이를 복소 표현으로 변환하면 $z_i = e^{i\theta_i}$ 가 되며, 시스템의 전역 잠재 표현은 다음과 같은 고차원 단위 복소 벡터로 정의됩니다.

$$\mathbf{z}(t) = \left[e^{i\theta_1(t)}, e^{i\theta_2(t)}, \dots, e^{i\theta_N(t)} \right]^T \in \mathbb{C}^N$$

2.2. 상태각(Phase)과 고유 진동수(Frequency)의 이중성

이 패러다임에서 고차원 잠재 표현은 고정된 상수가 아닌 이중적 정체성을 가집니다.

- 과도적 잠재 표현 (Transient State): 시간에 따라 빠르게 회전하는 위상각 벡터 $\boldsymbol{\theta}(t) = [\theta_1(t), \dots, \theta_N(t)]$
- 구조적 잠재 표현 (Invariant State): 외부 자극(입력 데이터)과 결합 구조(K)가 상호작용한 결과로 나타나는 정상 상태(Steady-state)의 고유 주파수 분포 $\boldsymbol{\Omega} = [\dot{\theta}_1, \dots, \dot{\theta}_N]$ 및 위상 고정 관계성(Phase-

locking Matrix) $P_{ij} = \cos(\theta_i - \theta_j)$

즉, 데이터의 고차원 특징은 뉴런의 '세세기 강도'가 아니라, 뉴런들끼리 '언제 발화하여 싱크(Sync)를 맞추는가'라는 시간적 타이밍과 정렬 패턴으로 인코딩됩니다.

3. 심층 표현 학습(Deep Representation Learning)의 구성 원리

그렇다면 위상 동기화 패러다임 하에서 '심층 표현 학습'은 어떻게 구조화되고 데이터를 점진적으로 고수준의 표현으로 정제할까요? 핵심 메커니즘은 다음 세 가지 단계로 구현됩니다.

3.1. 다단계 동역학적 이완(Dynamical Relaxation)과 층(Layer)의 전개

기존 신경망의 레이어 적층($l \rightarrow l + 1$)이 정적인 선형 대수 매핑과 비선형 활성화 함수(ReLU 등)의 결합이었다면, 위상 동기화 모델의 레이어는 물리적인 이완(Relaxation) 시간의 축적이자 수치적 상미분방정식(ODE)의 적분 단계입니다.

- 레이어 전방향 연산: 입력 데이터 $\mathbf{x}$ 는 결합 진동자계의 고유 진동수 입력 ω 나 외력 장(External Field)으로 주입됩니다.
- 시간 경과에 따른 정보 흐름:

$$\frac{d\theta_i}{dt} = \omega_i(\mathbf{x}) + \sum_{j=1}^N K_{ij}(\mathbf{W}) \sin(\theta_j - \theta_i)$$

이 미분방정식을 풀이 스텝 $t = 0 \rightarrow \tau$ 동안 흘려보내는 것 자체가 하나의 '심층 표현 학습의 층(Layer) 연산'을 대체합니다. 즉, 물리적 시간 축이 심층망의 '깊이(Depth)' 역할을 담당하며, 시스템의 불일치 에너지를 최소화하고 가장 지배적인 정상 상태로 이완시킵니다.

3.2. 동기화에 의한 결합 (Binding-by-Synchrony)과 재규격화(Renormalization)

심층 학습의 정수는 미시적인 데이터(예: 이미지의 개별 픽셀)에서 거시적인 추상적 개념(예: 강아지 객체)으로의 계층적 추상화입니다. 위상 동역학은 이를 '동기화에 의한 결합(Binding)'과 '재규격화군(RG) 흐름'의 물리 현상으로 해결합니다.

- 미시적 스케일 (얇은 레이어): 개별 진동수 차이가 커서 서로 제각각 회전하지만, 국소적인 유사성에 의해 작은 결합 군집(Local Phase-coherent Clusters)을 형성합니다 (예: 사물의 경계선, 모서리 검출).
- 거시적 스케일 (깊은 레이어): 정보가 전파되며 결합 강도가 강화되고, 미시적 주파수 변동이 서서히 통합(Coarse-graining)됩니다. 마침내 시스템이 임계 결합 강도 K_c 를 넘어서는 상전이(Phase Transition) 지점에 도달하면, 관련된 미시적 정보들이 동일한 위상 평면 위로 일시에 빨려 들어가 정렬되는 전역적 동기화(Global Synchronization)가 발생합니다.
- 이 결합(Binding) 과정을 통해 신경망은 무의미한 미시적 변동(노이즈)을 정보이론적으로 걸러내고 (Marginalize out), 유의미한 거시적 형상(표현)만을 최상위 레이어의 지배 위상(Master Phase)으로 남겨

놓습니다.

3.3. 정보 압축(MCR²)과 기하학적 분리의 위상 기하학적 공식화

기존 화이트박스 학습(CRATE, MCR²)의 목표는 잠재 표현의 공분산 행렬식을 조절하여 군집 내 변동 (Compress)은 줄이고 군집 간 거리(Sparsify)는 극대화하는 것이었습니다. 위상 동기화 딥러닝은 이를 위상 변위(Phase Shift)와 질서 매개변수(r)의 기하학으로 직관적으로 달성합니다.

- 군집 내 압축 (Intra-class Compression): 동일 클래스 혹은 연관성 높은 토큰을 나타내는 진동자들은 위상각의 차이를 0으로 수렴시킵니다 ($\theta_i \approx \theta_j$). 이 상태는 질서 매개변수 $r_c \rightarrow 1$ 이 되는 상태이며, 위상 정보 공간 내에서 부피(Volume)가 극도로 축적·압축됨을 의미합니다.
- 군집 간 분리 (Inter-class Orthogonality): 서로 다른 클래스 혹은 무관한 정보들은 서로 완벽하게 반대 방향의 위상을 가리키도록 밀어냅니다 (이상 현상, Out-of-phase).

$$\theta_{\text{class A}} - \theta_{\text{class B}} \approx \pi$$

이 관계는 직교하는 독립적인 부분공간(Orthogonal Subspaces)으로의 매핑과 수학적으로 동치이며, 기하학적 혼선 없이 서로 다른 표현을 완벽하게 격리해 냅니다.

4. 요약 및 패러다임 대비

위상 동기화 기반 딥러닝은 기존의 정적이고 통계적인 확률 평형에 기대던 인공지능을 지속적으로 진동하고 흐르는 동적 시간의 최적화계로 바꾼 아키텍처입니다.

분석 차원	기존 심층 표현 학습 (RBM / DNN)	위상 동기화 기반 표현 학습 (AKOrN / KuraNet)
잠재 뉴런 상태	실수 크기 (Scalar Magnitude, $z \in \mathbb{R}$)	회전 위상각 및 주파수 ($\theta \in [0, 2\pi], \omega \in \mathbb{R}$)
잠재 공간 토폴로지	고차원 유클리드 공간 ($\mathbb{R}^d$)	고차원 토러스(T^n) 및 초구면(S^{d-1}) 표면
심층 표현 학습 기전	다층 가중치 사영 및 비선형 임계 처리 (Relu 등)	연속 시간 축에서의 상미분방정식(ODE) 적분 및 완화
정보 압축 원리	공분산 행렬의 기하학적 부피 최소화 (MCR^2)	동기화 유도를 통한 위상 수렴 및 질서도($r \rightarrow 1$) 증가
클래스 분리 원리	직교 기저(Orthogonal Basis)로의 사영	서로 다른 동기화 군집 간의 상호 반대 위상각 배치 ($\Delta\theta \approx \pi$)

분석 차원	기존 심층 표현 학습 (RBM / DNN)	위상 동기화 기반 표현 학습 (AKOrN / KuraNet)
신경과학적 타당성	시냅스 신호 전달 세기 이론	위상 전파 및 '동기화에 의한 결합(Binding)' 이론

5. 결론 및 비전

위상 동기화 기반 심층 표현 학습은 복잡한 데이터 분산을 '결합 진동자의 정렬 게임'으로 변환합니다. 학습 과정을 거치며 최적화된 결합 상수 Matrix K_{ij} 는 데이터 간의 내재된 기하학적 관계를 대변하는 코드북이 되며, 최종 정상 상태의 위상 각도들이 고차원 특징 분포를 압축한 '표현(Representation)'이 됩니다.

이 패러다임은 설명 가능한 지능(질서 지표 r 의 물리학적 변화 추적)을 가능케 할 뿐만 아니라, 향후 연속 미분 계산의 물리적 기질인 아날로그 전용 반도체(Anlog Silicon / Photonic) 하드웨어와 만나 기존 인공지능의 컴퓨팅 전력 한계를 타파할 결정적 무기가 될 것입니다.