

# 트랜스포머 기반 시계열 예측(TSF)의 한계와 위상 동기화 기반 접근법

## 1. 기존 트랜스포머 기반 시계열 예측(TSF)의 한계와 문제점

최근 몇 년간 트랜스포머(Transformer) 아키텍처는 시계열 예측(Time-Series Forecasting, TSF) 분야에서 널리 활용되어 왔으나, 자연어 처리(NLP)와 달리 시계열 데이터가 가진 고유한 통계적·물리적 특성으로 인해 다음과 같은 치명적인 한계에 직면해 있습니다.

### 1.1. 시간적 귀납 편향(Temporal Inductive Bias)의 부재와 순열 불변성(Permutation Invariance)

- 문제점: 트랜스포머의 자가 주의집중(Self-Attention) 메커니즘은 순서가 뒤바뀌어도 동일한 결과를 출력하는 순열 불변(Permutation-invariant) 특성을 가집니다. 이를 해결하기 위해 포지셔널 인코딩(Positional Encoding)을 더해주지만, 이는 인위적인 좌표 주입일 뿐 신경망 자체가 시간의 연속성(Temporal Continuity)과 인과적 흐름을 보존하도록 설계된 것은 아닙니다.
- TSF 한계: 시계열 데이터의 핵심인 트렌드(Trend)와 연속적인 물리적 인과 관계를 매끄럽게 모델링하지 못하고, 과거 스텝 간의 정적인 상관관계(Correlation) 매핑에만 집착하여 미래 예측 시 누적 오차가 빠르게 증가하는 현상(Error Propagation)이 발생합니다.

### 1.2. 이차 시간 복잡도( $O(L^2)$ )로 인한 장기 이력(Long-Range Context) 모델링의 병목

- 문제점: 입력 시퀀스 길이  $L$ 이 늘어날수록 자가 주의집중 연산의 메모리 및 시간 복잡도는  $O(L^2)$ 로 기하급수적으로 증가합니다.
- TSF 한계: 기후 변화, 금융 사이클, 공장 센서 모니터링 등 초장기 이력(Long-Lookback Window) 정보가 중요한 도메인에서 모델의 실시간 구동 및 학습이 불가능해집니다. 이를 해결하기 위해 정보의 누락이 발생하는 희소 어텐션(Sparse Attention) 계열 모델(Infomers 등)이 제안되었으나, 여전히 샘플링 오차와 정보 손실 문제를 안고 있습니다.

### 1.3. 위상 전이(Phase Shift)와 주파수 변동(Frequency Variation)에 대한 취약성

- 문제점: 실세계 시계열 데이터는 계절성(Seasonality)이 변하거나 주기가 밀리고 당겨지는 위상 변위(Phase Shift)와 주파수 변동(Frequency Drift)을 빈번하게 겪습니다.
- TSF 한계: 점 단위(Point-wise) 값 매핑에 치중하는 트랜스포머는 이러한 주기의 시간적 밀림 현상을 선형/비선형 외삽으로 매끄럽게 보정하지 못합니다. 주기가 조금만 어긋나도 예측 성능이 극도로 왜곡되는 현상이 나타납니다.

## 1.4. 오버스무딩(Over-smoothing)에 따른 미세 고주파 패턴 상실

- 문제점: 트랜스포머 레이어가 깊어질수록 모든 토큰의 특징 벡터가 하나의 평균값으로 수렴해가는 오버스무딩 현상이 발생합니다.
- TSF 한계: 시계열 데이터 내에 존재하는 과도기적 스파이크(Transient Spike), 급격한 주파수 변화, 이상 징후(Anomaly)와 같은 고밀도 국소 정보가 레이어를 통과하며 묻개지고 소실됩니다.

## 2. 위상 동기화 기반 딥러닝을 이용한 TSF 구현 단계

결합 진동자 모델(예: 쿠라모토 모델)은 시계열 데이터를 회전하는 물리적 위상계로 변환하여 연속 시간 흐름 속에서 다중 주기성과 과거의 관성을 자연스럽게 학습합니다. 이를 이용해 시계열 예측(TSF) 모델을 구현하기 위한 5단계 접근 방법을 제시합니다.

단계 1: 시계열 입력의 고유 진동수( $\omega$ ) 및 위상( $\theta$ ) 인코딩 (Phase Encoding) 입력된 1차원 시계열 데이터(예: 주식 가격, 기온 변동 등)를 기하학적 원형 공간(Circular Manifold) 상의 물리량으로 변환하는 단계입니다.

- 구현 방법:
  - i. 원본 시계열  $x(t)$ 로부터 힐베르트 변환(Hilbert Transform) 또는 가버 필터(Gabor Filter) 형태의 미분 가능 인코더  $f_\phi$ 를 사용하여 순시 위상(Instantaneous Phase,  $\theta(0) \in [0, 2\pi]$ )과 회전 속도인 고유 진동수(Natural Frequency,  $\omega$ )를 추출합니다.

$$\theta_i(0), \omega_i = f_\phi(x(t))_i$$

- i. 다차원 시계열 채널 또는 개별 시간 스텝이 하나의 진동자 뉴런(Oscillator)으로 대응되어 고차원 토러스(Torus) 상의 초기 공간 분포를 형성하게 만듭니다.

단계 2: 시간적 기억 구현을 위한 관성(Inertia) 기반 2차 동역학계 설계

과거 주행 경로와 모멘텀을 물리적으로 보존하여 장기 시계열 의존성(Long-term dependency)을 유지하기 위해 2차 쿠라모토 동역학계를 설계합니다.

- 구현 방법:
  - i. 시스템의 레이어 전파 연산을 1차가 아닌 가속도 항(관성)이 존재하는 2차 상미분방정식(2nd-Order ODE with Inertia)으로 수립합니다.

$$m\ddot{\theta}_i + \alpha\dot{\theta}_i = \omega_i + \sum_{j=1}^N K_{ij} \sin(\theta_j - \theta_i)$$

- i. 여기서 질량( $m$ )은 시스템의 관성(Momentum) 역할을 하며, 감쇠 항( $\alpha$ )은 에너지를 소실시키는 저항 역할을 합니다.
- ii. 물리적 이점: 이 구조는 과거의 활동 이력이 미래 상태에 관성으로 작용해 지연 전파되는 히스테리시스(Hysteresis, 이력 현상)를 신경망 내에 자연스럽게 유도합니다. LSTM의 복잡한 게이트나 트랜스

포머의 거대한 메모리 공간 없이도 장기 기억을 완벽히 보존합니다.

### 단계 3: 데이터 종속적 결합 가중치( $K_{ij}$ ) 학습 및 동적 이완 (Coupling & Relaxation)

어텐션 가중치 역할을 하는 진동자 간 결합 강도 행렬  $K_{ij}$ 를 동적으로 연산하고 시스템을 최적의 합의 상태로 흘려보내는 단계입니다.

- 구현 방법:

- 토큰 간의 기하학적 관계를 파악하기 위해, 입력 문맥에 기반하여 내용 종속적 결합 세기를 동적으로 생성하는 신경망(Amortized Coupling Net)을 적용하여 결합 행렬  $K_{ij}$ 를 출력합니다.
- 수립된 미분방정식을 오일러(Euler) 혹은 Runge-Kutta 4차(RK4) 수치 솔버를 이용해 일정 이완 시간(Relaxation Time)  $T$  동안 실시간 적분합니다.
- 이 이완 과정에서 유사한 주기와 패턴을 가진 요인들은 동일한 위상 평면으로 서로 끌어당겨 정렬되고 (Phase-locking), 무관한 노이즈 요인들은 위상이 서로 상쇄(Destructive Interference)되어 걸러집니다.

### 단계 4: 안티-오버싱크 제어를 통한 다중 스케일 임계 상태 유지 (Criticality Tuning)

시간 흐름에 따라 모든 진동자가 단 하나의 위상각으로 뭉쳐 개성을 잃어버리는 과도한 동기화(Over-synchronization) 현상을 방지하는 단계입니다.

- 구현 방법:

- 시스템의 무질서와 질서의 경계면인 임계 상태(Criticality)를 정교하게 유지하는 제어 메커니즘을 이식합니다.
- 최신 PhaseGPT의 접근법처럼, 결합력이 지나치게 강해질 경우 이를 억제하는 적응형 결합 제어 (Anti-over-sync control) 장치를 가동하여 질서 매개변수( $r$ )가 완벽한 1로 붕괴하지 않고  $r \approx 0.6 \sim 0.8$ 의 준안정 상태(Metastable State)를 유지하도록 설계합니다.
- 이를 통해 고주파 노이즈는 차단하면서도 시계열 데이터 고유의 다양성(Entropy)과 미세 변동 패턴을 손실 없이 유지합니다.

### 단계 5: 최종 위상 공간의 미래 예측치 디코딩 (Readout & Decoding)

이완 과정을 거쳐 미래 타겟 시간대로 정렬 및 투영된 진동자들의 최종 위상각을 다시 실제 1차원 도메인의 예측치로 복원하는 단계입니다.

- 구현 방법:

- 최종 수렴된 진동자들의 위상각 상태  $\theta(T)$ 를 복소 평면 상의 기하 벡터인 코사인 및 사인 값의 쌍  $[\cos \theta(T), \sin \theta(T)]$ 로 투영합니다.
- 이 기하학적 고차원 매니폴드 표현을 역변환 디코더(Decoder Layer) 및 주파수 복원 헤드에 복과시켜, 원래 도메인의 미래 타임스텝의 연속적인 파형 데이터  $\hat{y}(t + \Delta t)$ 로 최종 디코딩합니다.

$$\hat{y}(t + \Delta t) = \mathbf{W}_{\text{out}} \begin{bmatrix} \cos \theta(T) \\ \sin \theta(T) \end{bmatrix} + \mathbf{b}_{\text{out}}$$

### 3. 요약 및 성능 대비 분석

위상 동기화 기반 TSF는 기존 트랜스포머 모델의 수학적 결함을 물리학의 고유 동역학적 특성으로 완벽히 보완합니다.

| 비교 요소     | 기존 트랜스포머 기반 TSF (예: Informer, PatchTST) | 위상 동기화 기반 TSF (예: KuraNet, KuramotoGNN)           |
|-----------|-----------------------------------------|---------------------------------------------------|
| 시간의 표현    | 포지셔널 코드로 고정된 인위적 이산 시간                  | 미분방정식으로 전개되는 자연스러운 연속 시간                          |
| 장기 기억 장치  | 과거 이력 전체의 자가 주의집중 행렬 복사                 | 2차 ODE의 물리적 관성(Inertia) 및 히스테리시스                  |
| 위상/주파수 변동 | 훈련 범위를 벗어난 주기 변이에 대응 불가                 | 위상각 변위( $\theta_j - \theta_i$ ) 학습을 통한 유연한 위상 동조  |
| 연산 복잡도    | 시퀀스 길이 증가에 따라 $O(L^2)$ 급증               | 국소 결합(Locally Coupled) 구성 시 $O(L)$ 수준의 선형 스케일링 가능 |
| 과도 상태 복원력 | 오버스무딩으로 세밀한 국소 특징 상실                    | 준안정성(Metastability) 유도로 고주파 국소 변동 완전 보존           |

### 결론 및 향후 제언

보고서에서 정리한 바와 같이, 기존 트랜스포머 기반 TSF 모델은 순열 불변성 해결의 한계, 장기 이력 입력 시  $O(L^2)$  연산 병목, 급격한 위상/주파수 변동 취약성 등의 명확한 한계를 가지고 있습니다. 이를 해결하기 위해 제시한 위상 동기화 기반 딥러닝 아키텍처는:

- 입력 데이터를 Instantaneous Phase( $\theta$ )와 Frequency( $\omega$ )로 인코딩하고,
- 관성이 포함된 2차 쿠라모토 동역학을 적용하여 자연스러운 기억력(히스테리시스)을 부여하며,
- 안티-오버싱크 제어를 적용해 준안정 임계 상태를 유지하며 디코딩하는 단계를 거쳐 혁신적인 시계열 예측을 실현할 수 있습니다.

특히 이 방식은 장기 시퀀스를 다룰 때 어텐션의 정적 행렬 복사본을 유지할 필요 없이 물리적인 위상 정렬을 진행하므로 메모리 효율이 극대화되며, 장기 시계열 예측 프로젝트의 새로운 강력한 돌파구가 될 것입니다.